



Machine Learning

Classification: Nearest Neighbors

Dr. Mehran Safayani


safayani@iut.ac.ir


https://people.iut.ac.ir/en/safayani


https://www.aparat.com/mehran.safayani


https://github.com/safayani/machine_learning_course

https://git.iut.ac.ir/safayani/courses/-/tree/main/Machine_Learning_course



Department of Electrical and computer engineering, Isfahan university of technology, Isfahan, Iran

Classification

همانند مسئله رگرسیون است با این تفاوت که y مقدار گسسته می گیرد.

Binary classification (دسته بندی دودویی):

$y \in \{c_1 , c_2\}$, c_i : برچسب کلاس

$y \in \{ -1 , +1\}$, $y \in \{ 0 , +1\}$

هیچ ترتیبی بین دو کلاس وجود ندارد

Multi-class classification (دسته بندی چند کلاسه):

$y \in \{c_0 , c_2 , \dots , c_{k-1}\}$

$y \in \{0 , 1 , 2 , \dots , k-1\}$





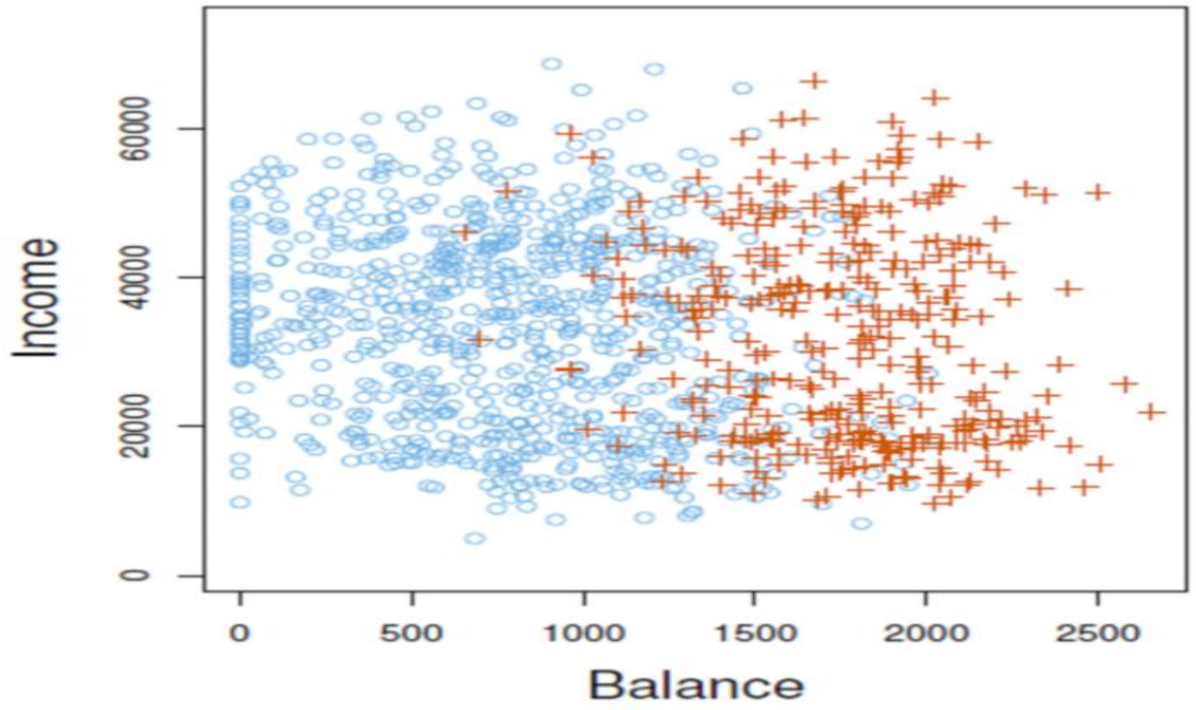
مثال

می خواهیم بدانیم که یک تراکنش کارت اعتباری جعلی است یا اصلی. با استفاده از اطلاعاتی نظیر تراکنش های گذشته و ....

مثالی دیگر:

نارنجی : بدحساب (مبلغ ماهیانه را به موقع پرداخت نمی کند)

آبی: خوش حساب



دسته بند

یک دسته بند فضای ورودی را به ناحیه هایی متعلق به هر کلاس تقسیم میکند. مرز این ناحیه ها را مرز تصمیم (Decision boundry) میگویند.

دسته بند میتواند خطی یا غیر خطی باشد.

دسته بند خطی از ترکیب خطی ویژگی ها استفاده میکند.

$$y = f\left(\sum \theta_j x_j\right)$$

f تابعی است که ترکیب خطی را به خروجی دسته بندی تبدیل میکند.

$$f(\mathrm{x}) = \begin{cases} 1 & \text{if } \theta^{\top} x \geq \tau \\ 0 & \text{otherwise} \end{cases}$$

Decision boundary

$$\theta_1 x_1 + \theta_2 x_2 + b \geq \tau \quad \text{then class 1}$$

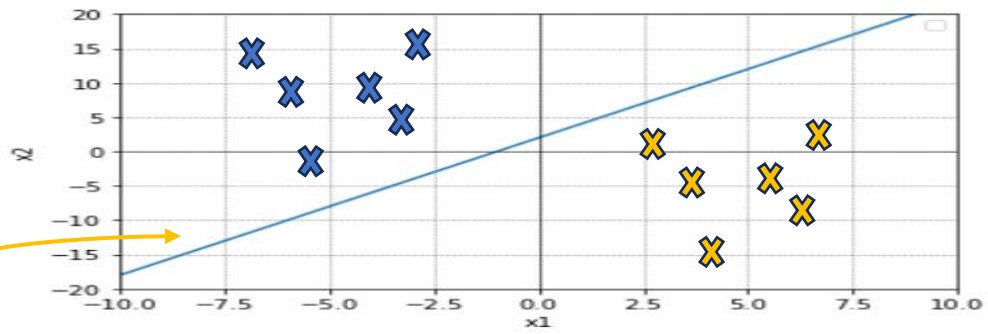
$$\underbrace{b - \tau}_{b'} \geq 0$$

Decision boundary:

$$\theta_1 x_1 + \theta_2 x_2 + b = 0$$

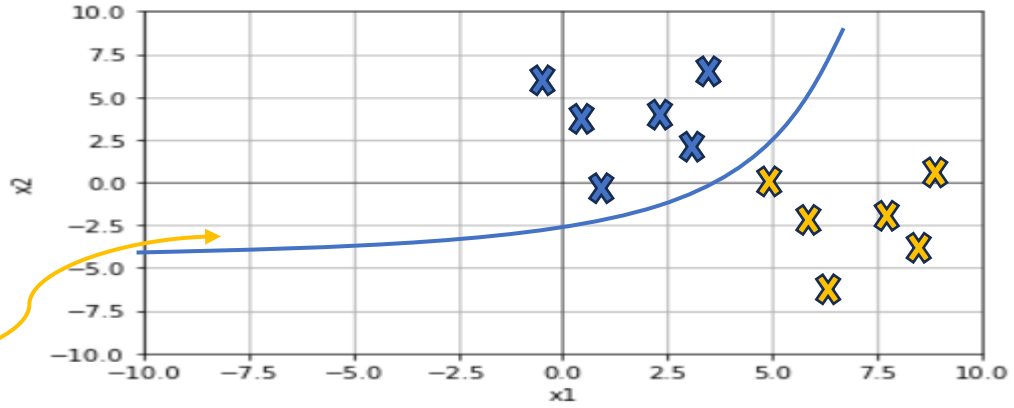
$$x_2 = -\frac{\theta_1}{\theta_2} x_1 - \frac{b}{\theta_2}$$

مرز تصمیم
خطی



$$\theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 = 0$$

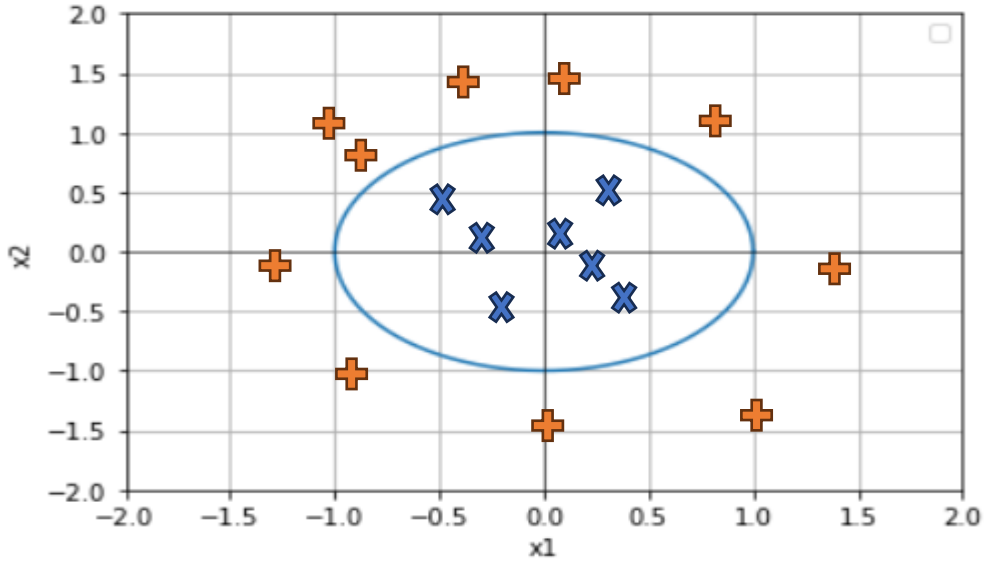
مرز تصمیم
غیرخطی



Decision Boundary

$\theta_1 x_1^2 + \theta_2 x_2^2 +$ b = o , θ_1 =1 , θ_2 =1 , b= -1

$x_1^2 + x_2^2 = 1$



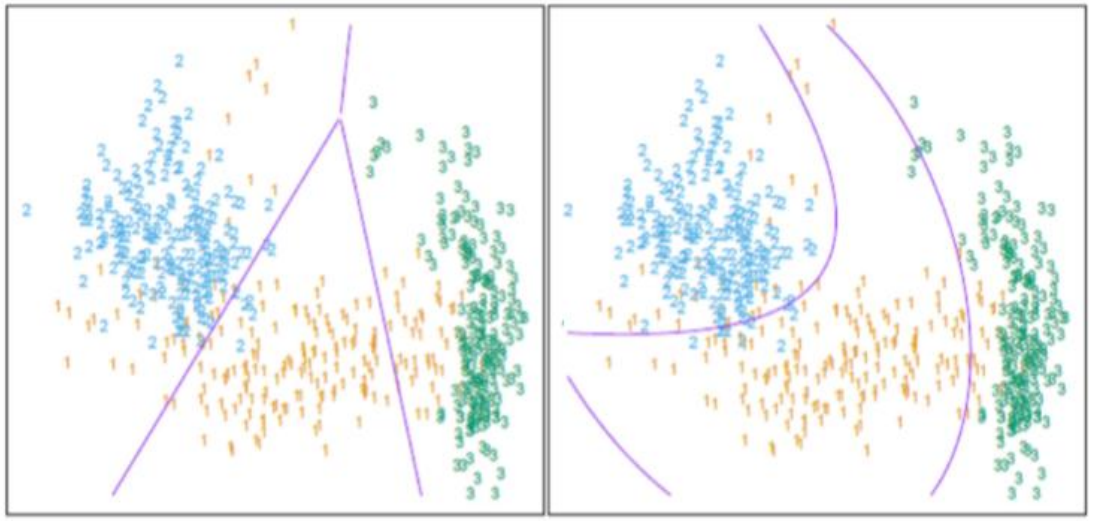


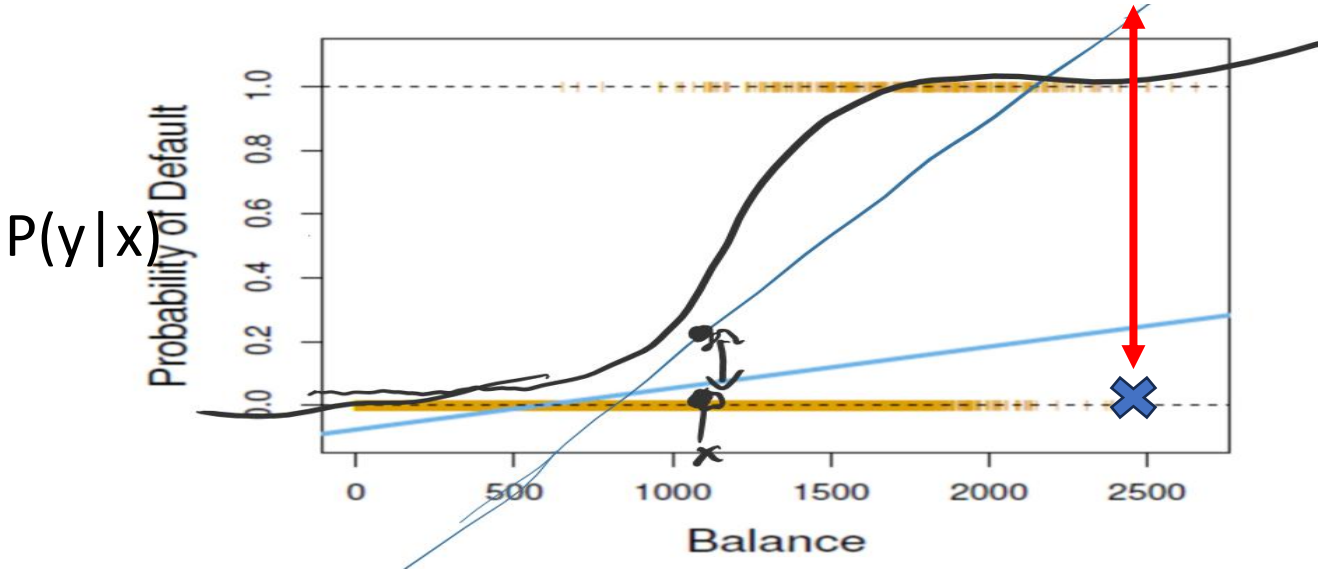
FIGURE 4.1. *The left plot shows some data from three classes, with linear decision boundaries found by linear discriminant analysis. The right plot shows quadratic decision boundaries. These were obtained by finding linear boundaries in the five-dimensional space* $X_1, X_2, X_1X_2, X_1^2, X_2^2$. *Linear inequalities in this space are quadratic inequalities in the original space.*

نکته: مرز تصمیم در دسته بند خطی در فضای ویژگی اولیه (نه فضای ویژگی توسعه یافته) لزوما خطی نیست.

مرز تصمیم در دسته بند خطی در فضای ویژگی توسعه یافته خطی است.

دسته بندی به صورت حالت خاص یک مسئله رگرسیون

- Y=0 , y=1 را میتوان احتمال تعلق به هر یک از کلاس ها در نظر گرفت.
- خروجی مدل میتواند اعداد منفی یا بزرگتر از یک باشد.
- تعداد کمی نقطه میتواند جهت خط را به میزان زیادی تغییر دهد مانند اضافه کردن چند نقطه با بالانس خیلی زیاد



Nearest Neighbor

دسته بند نزدیکترین همسایگی

- نمونه های نزدیک برچسب یکسانی دارند.
- نزدیکی را با فاصله اقلیدسی میتوان اندازه گرفت.
- با داشتن یک محموعه آموزشی s_{train} و یک داده x به دنبال x^* که نزدیکترین نقطه به x است میگردیم و برچسب را برابر $y^*(x^*$ برچسب$)$ با قرار میدهیم.

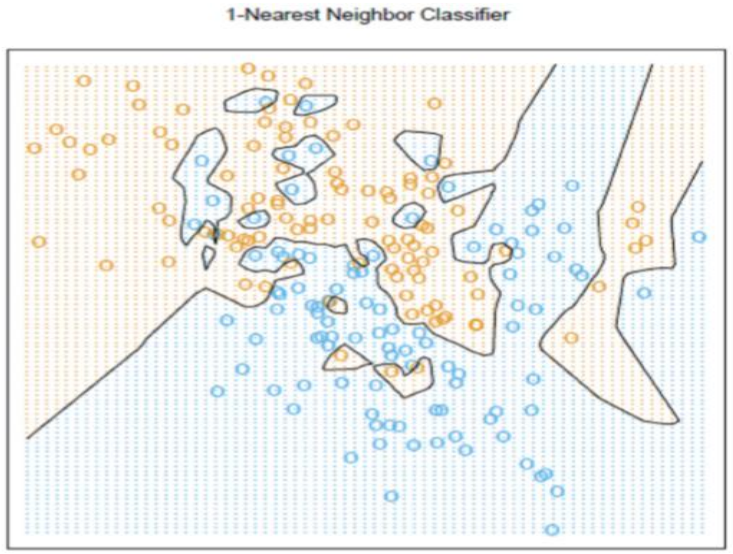


FIGURE 2.3. *The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1), and then predicted by 1-nearest-neighbor classification.*